

## Escopo da Demo — Contattos+ · Assistente de Dados via Chat

**Data:** 18/07/2026 · **Elaborado por:** Mulino Tech · **Versão:** 1.2 (arquitetura própria, sem Botpress) **Profundidade:** Executivo · **Escopo:** Demo comercial (visão simplificada do PoC), construível em 1 semana **Base:** derivado do Briefing Técnico completo v1.0 + discovery gravado de 17/07/2026

---

### 1. Contexto e objetivo da demo

A Contattos+ pediu, na reunião comercial, algo concreto para ver funcionando. Esta demo é a **versão simplificada e demonstrável** da solução: um assistente onde os times de compras e financeiro perguntam números da empresa em linguagem natural e recebem a resposta na hora, com controle de quem vê o quê.

O objetivo não é integrar ao ERP real (isso é o PoC) — é **provar a experiência e a confiabilidade** com dados realistas, para o cliente sentir o valor e aprovar o projeto. O próprio Matheus abriu essa porta na reunião: aceita ver a ferramenta rodando com dados fictícios.

**Critério de sucesso da demo:** o cliente vê, ao vivo, (a) o alerta de quebra de estoque acender sozinho, (b) uma resposta consistente em segundos sem abrir chamado, (c) um usuário sem permissão sendo recusado, e (d) a linha de custo por conversa. Os quatro pontos batem direto nas dores priorizadas do Matheus.

#### Dores priorizadas (do discovery)

1. **Visibilidade de estoque ruim** — a equipe não enxerga o que está acontecendo no estoque.
  2. **Quebra/divergência de estoque** — “entram 100 peças, aparecem 60”; some e reaparece. (*clímax da demo*)
  3. **Margem apertada / dinheiro escoando** — falta de visibilidade de fornecedor e estoque come a margem.
  4. **Decisão travada por falta de dado** — gestor não decide porque não acessa o relatório; informação se perde no caminho.
- 

### 2. Comportamentos que a demo mostra

| #  | Comportamento                                                                                                               | Dor atacada |
|----|-----------------------------------------------------------------------------------------------------------------------------|-------------|
| B1 | <b>Alerta de quebra de estoque (clímax):</b> “Do que entrou da Tramontina este mês, quanto ainda está em estoque?” → a demo | 1 + 2       |

|    |                                                                                                                                                                                               |                        |
|----|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------|
| #  | Comportamento<br>devolve <i>entrou X / saldo Y / quebra de Z</i><br>com uma <b>luz amarela</b> .                                                                                              | Dor atacada            |
| B2 | <b>Visibilidade de estoque:</b> “Quanto temos em estoque da Tramontina?” / “Como está o giro do fornecedor X?” → número com contexto, no formato pedido (número, tabela ou gráfico).          | 1                      |
| B3 | <b>Participação de fornecedor + comparação:</b> “Quanto a Tramontina participou das compras no último trimestre?” (agrupando CNPJs) e “este mês vs. mesmo mês do ano passado” (+ variação %). | 4                      |
| B4 | <b>Decisão em segundos + recusa por permissão:</b> usuário de “compras” recebe a resposta na hora (autonomia); ao pedir margem/custo restrito, o sistema recusa com clareza (moderação).      | 5 + governança         |
| B5 | <b>Honestidade + custo:</b> pergunta fora do catálogo ou falha simulada → não inventa número; e toda resposta exibe a linha de custo estimado da conversa.                                    | confiabilidade + custo |

---

### 3. Fluxo da informação

**Em resumo:** a IA só entende a pergunta e formata a resposta; quem busca e calcula o número é o nosso serviço no Cloudez, consultando o banco. O número nunca sai da “cabeça” da IA — é isso que torna a resposta confiável.

- **Onde busca:** base sintética MySQL no Cloudez (mesma tecnologia do ERP real Cetel/Citel → “sente real”).
- **Como interpreta:** Haiku 4.5 (via SDK da Anthropic, com nossa chave) extrai intenção e parâmetros em JSON e aciona uma consulta pronta do catálogo — **não escreve SQL livre**.
- **Como devolve:** o orquestrador Node retorna o dado (e a URL do gráfico); a IA formata a mensagem final no nosso web chat, sempre citando período e fonte.




Figura 1 — Da pergunta no

chat à resposta validada (ou recusa).

### 4. Arquitetura da solução

**Em resumo:** tudo roda no nosso sandbox no Cloudez; um “cardápio” de consultas prontas garante precisão e controle de acesso — sem tocar em nada da infra do cliente e sem depender de plataforma externa.




Figura 2 —

*Tudo no nosso Cloudez; IA e gráfico como serviços externos chamados por código.*

| Componente            | Responsabilidade                                                 | Tecnologia                                     |
|-----------------------|------------------------------------------------------------------|------------------------------------------------|
| Web chat              | Canal de entrada/saída e identidade simulada do usuário          | HTML/CSS/JS servido pelo Node                  |
| Orquestrador          | Fluxo da conversa, chamadas de IA, permissões                    | Node 20 + Fastify no Cloudez                   |
| Catálogo de consultas | 3–4 consultas parametrizadas + metadados de permissão por perfil | SQL + JSON/YAML                                |
| Base sintética        | Fornecedores, compras, entradas e saldo (~12 meses)              | MySQL no Cloudez                               |
| Camada de permissões  | Mapa e-mail → perfil → métricas liberadas                        | JSON fixo (hardcoded na demo)                  |
| IA                    | Extração de intenção + formatação                                | Haiku 4.5 via SDK da Anthropic (chave própria) |
| Gráficos              | Gráfico como imagem no chat                                      | QuickChart.io (sem custo de IA)                |
| Contador de custo     | Estima tokens/custo por conversa e exibe no chat                 | Função em Node + log                           |

**Por que catálogo e não “IA escreve SQL”:** confiabilidade (consulta pronta  $\approx 100\%$  de acerto no escopo), segurança (cada métrica amarrada a um perfil) e custo (extrair parâmetros usa modelo barato). O dado factual vem sempre do banco via código, nunca da “memória” do modelo.

**Alavancas de custo:** roteamento (modelo barato para extração/formatação); prompt caching no system prompt ( $\sim 90\%$  no contexto repetido do catálogo); gráficos por código (custo zero de IA); contador de custo desde o dia 1.

---

## 5. Stack recomendada

| Camada              | Tecnologia                   | Justificativa                                                           |
|---------------------|------------------------------|-------------------------------------------------------------------------|
| Backend             | Node 20 + Fastify            | Afinidade do Cloudez com Node; leve e rápido; controle total            |
| Hospedagem          | Sandbox Mulino no Cloudez    | Já existe; custo incremental da demo $\approx$ zero                     |
| Canal               | Web chat próprio             | Controle total do “uau”; sem marca d’água nem dependência externa       |
| Base de dados       | MySQL (seed sintético)       | Mesma tecnologia do ERP real $\rightarrow$ “sente real” na apresentação |
| Catálogo/permissões | SQL parametrizado + JSON     | Precisão e controle de acesso no escopo da demo                         |
| IA                  | SDK da Anthropic (Haiku 4.5) | Extração de parâmetros + formatação; billing direto na nossa chave      |
| Gráficos            | QuickChart.io                | Determinístico e gratuito; sem infra e sem custo de IA                  |

---

## 6. Modelos de IA por tarefa

**Em resumo:** a IA só faz duas tarefas fáceis — extrair parâmetros e formatar. Como os dados da demo são sintéticos, não há questão de compliance; usamos o modelo barato direto pela nossa chave.

*Preços reconfirmados em 18/07/2026 (páginas oficiais + agregadores).*

### Tarefa A — Extração de intenção e parâmetros (maior volume)

| Modelo                  | Preço in/out<br>(US\$/MTok) | Nota                                                                           |
|-------------------------|-----------------------------|--------------------------------------------------------------------------------|
| <b>Claude Haiku 4.5</b> | 1,00 / 5,00                 | Aderência a<br>instrução/JSON forte;<br>latência baixa; chave já<br>disponível |
| Gemini 3.1 Flash-Lite   | 0,25 / 1,50                 | Mais barato; alternativa<br>direta                                             |
| Gemini 2.5 Flash-Lite   | 0,10 / 0,40                 | O mais barato dos<br>grandes provedores                                        |

**Recomendado: Haiku 4.5** — melhor garantia de JSON estável (o ponto sensível para o “uau” não quebrar ao vivo). US\$ 1/5 por MTok com caching é irrisório no volume de demo. **Custo:** US\$ 1,00/MTok input, US\$ 5,00/MTok output (fonte: página oficial Anthropic, consultado em 18/07/2026). **Alternativa:** Gemini 3.1/2.5 Flash-Lite se quiser custo mínimo (fonte: Google/agregadores, 18/07/2026).

### Tarefa B — Formatação da resposta

**Recomendado:** mesmo Haiku 4.5 — formatar número/tabela é trivial e o custo marginal é desprezível.

*(A demo não gera SQL por IA: o catálogo é fixo e escrito à mão.)*

---

## 7. Estimativa de custo da demo

**Em resumo:** a demo praticamente não tem custo de operação — o Cloudez já é pago, o gráfico é grátis e o token é centavo.

| Item                                                | Conservador (alto)          | Otimista (baixo) |
|-----------------------------------------------------|-----------------------------|------------------|
| Tokens IA (Tarefas A+B, com caching)                | ~US\$ 5 (todo o período)    | ~US\$ 1          |
| Cloudez (sandbox já existente) + MySQL + QuickChart | US\$ 0 incremental / grátis | US\$ 0           |
| <b>Total incremental do período</b>                 | <b>~US\$ 5</b>              | <b>~US\$ 1</b>   |

### Tabela de premissas

| Premissa                    | Valor assumido                                | Origem                     |
|-----------------------------|-----------------------------------------------|----------------------------|
| [PREMISSA] Usuários da demo | ~5–10 (perfis compras + financeiro simulados) | Estimativa de demonstração |

| Premissa                                | Valor assumido                                 | Origem                                                        |
|-----------------------------------------|------------------------------------------------|---------------------------------------------------------------|
| [PREMISSA] Consultas no período         | ~200–600 no total (dev + teste + apresentação) | Estimativa de demonstração                                    |
| [PREMISSA] Tokens por consulta          | ~2k in (1,5k cacheado) + ~250 out, 2 chamadas  | Padrão de sistemas similares da Mulino                        |
| [PREMISSA] Câmbio Horas Mulino (Silvia) | US\$ 1 = R\$ 5,60<br>Fora desta estimativa     | Aproximação — validar<br>Dimensionar após aprovação do escopo |

---

## 8. Critérios de aceite da demo

1. Dado um usuário “compras”, quando perguntar entrada vs. saldo de um fornecedor no período, então a demo apresenta *entrou X / saldo Y / quebra Z* refletindo exatamente a base sintética (0 divergência) e acende a luz amarela quando a quebra passa do limiar.
  2. Dado um usuário “compras”, quando perguntar estoque/giro de um fornecedor, então a resposta reflete a consulta e vem no formato pedido (número/tabela/gráfico).
  3. Dada uma pergunta de participação com agrupamento de CNPJ, quando processada, então todos os CNPJs do fornecedor são somados no resultado.
  4. Dada uma comparação entre períodos, quando processada, então os dois valores e a variação % aparecem corretos.
  5. Dado um usuário sem permissão para dado financeiro, quando pedir margem/custo, então o sistema recusa e nenhuma consulta é executada (verificável no log).
  6. Dada uma pergunta fora do catálogo ou uma falha simulada da base, quando recebida, então o sistema informa e não apresenta nenhum número.
  7. Dada qualquer resposta, quando entregue, então a linha de custo estimado da conversa é exibida.
  8. Dada uma consulta do catálogo, quando executada, então a resposta chega em  $\leq 5-8$  s [PREMISSA de latência de demo].
- 

## 9. Decisões travadas

- **Dores no escopo:** 1 (visibilidade), 2 (quebra de estoque — clímax), 4 (margem), 5 (decisão travada).
- **Fonte de dados:** base sintética MySQL no Cloudez, com nomes reconhecíveis do mundo de material elétrico (ex.: Tramontina, citada pelo próprio Matheus) e múltiplos CNPJs sob um mesmo fornecedor — máximo de realismo com zero dado sensível.
- **Arquitetura:** própria, 100% no Cloudez (web chat + orquestrador Fastify + MySQL), sem Botpress — controle total e sem trava de plano.

- **Modelo:** Haiku 4.5 direto via SDK da Anthropic (chave da Silvia).
  - **Canais:** web chat próprio como entrega garantida; Google Chat como stretch, implementado direto (app do Google Chat = webhook + cards JSON no Fastify, no Workspace da inpyx).
- 

### Plano de 1 semana (Silvia)

| Dia | Entrega                                                                                                                  | Pronto quando                                   |
|-----|--------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------|
| 1   | Base sintética MySQL (fornecedores/compras/entradas/saldo, ~12 meses, marcas reais + múltiplos CNPJs) + scaffold Fastify | Base consultável e servidor de pé               |
| 2   | Catálogo (participação c/ agrupamento CNPJ, comparação de período, estoque/giro) + cálculo de quebra + permissões (JSON) | Endpoints retornam número correto por parâmetro |
| 3   | Integração IA (Haiku via SDK Anthropic): pergunta → JSON de parâmetros + guardrail (só dispara consulta do catálogo)     | Extração estável nos casos do roteiro           |
| 4   | Formatação das respostas + card de luz amarela (alerta) + gráfico (QuickChart) + linha de custo por conversa             | Número, tabela, gráfico, alerta e custo no chat |
| 5   | Web chat próprio (UI servida pelo Fastify) + fluxos de recusa (permissão / fora de escopo / falha simulada)              | Os comportamentos B1–B5 rodando ponta a ponta   |
| 6   | Roteiro de demo com as consultas reais (Tramontina etc.) + testes dos critérios 1–8                                      | Critérios de aceite verdes                      |



| Dia | Entrega                                                                                   | Pronto quando |
|-----|-------------------------------------------------------------------------------------------|---------------|
| 7   | Buffer / polimento / stretch: app Google Chat (webhook + cards) ou ensaio da apresentação | —             |

### O que fica FORA da demo (fronteira para não estourar 1 semana)

Conexão real ao ERP via VPN · modelo de permissão completo por perfil · auditoria persistida · LGPD hardening · gatilhos proativos de quebra em produção · multi-departamento · memória semântica de perguntas frequentes.

Tudo isso é PoC/Fase 1+ — está no briefing técnico completo e entra depois que o cliente aprovar.

---

*Documento gerado pela Mulino Tech · escopo de demo v1.2 para revisão (Rodrigo → Silvia).*